Universidade de Coimbra
LIACD

Classificação de Atividades Humanas

Aluno: Tiago Carlos 2021218666
Aluno: Lucas Saraiva 2021218251

Maio
2025

Conteúdo

1 Introdução **1**

2 Análise Exploratória e Identificação de Outliers (3) **2**
2.1 Análise dos BoxPlots dos Módulos dos Vetores (3.1) 2
2.2 Análise da Densidade de Outliers (3.2) 4
2.3 Comparação entre Z-Score e BoxPlot (3.5) 5
2.4 Comparação do K-Mean com Z-Score (3.7) 7

3 Extração de Informação (4) **10**
3.1 Análise e Interpretação dos Resultados (4.1) 10
3.2 Extração de Features(4.2) 10
3.3 Análise do PCA (4.4) 12
3.4 Análise do Fisher e ReliefF (4.6) 12

4 Data Augmentation (1.B) **14**

5 Data Splitting Strategy (3.3.B) **15**

6 Model Learning (4.B) **16**

7 Avaliação (5.B) **17**

8 Potenciais Melhorias **18**

1 Introdução

O presente relatório tem como objetivo exercitar e consolidar conceitos centrais de uma pipeline de análise de dados passando por todas as suas fases fundamentais: preparação e limpeza dos dados, extração de características descritivas, seleção e/ou redução de atributos, e, por fim, aplicação de métodos de aprendizagem computacional.

O contexto do problema abordados insere-se na área de classificação de atividades físicas humanas, um domínio de crescente relevância em diversas aplicações, nomeadamente em contextos médicos, recreativos e de bem-estar. Através deste trabalho, pretende-se não apenas resolver um problema prático de classificação, mas também compreender e aplicar metodologias que são transversais a qualquer processos de análise de dados.

Para o desenvolvimento do projeto, foi utilizado o dataset FORTH-TRACE benchmark, que contém dados recolhidos a partir de cinco sensores (acelerómetro, giroscópio e magnetómetro) posicionados em diferentes partes do corpo humano (superior e inferior). O conjunto de dados foi obtido de 15 participantes, seguindo um protocolo experimental que envolveu 16 atividades distintas.

Os dados originais estão organizados em ficheiros CSV no formato partX/partXdevY.csv, onde X representa o identificador do participante e Y o identificador do dispositivo. Cada ficheiro contém medições correspondentes aos diferentes sensores, incluindo aceleração, velocidade angular e variação do campo magnético, bem como o timestamp e o rótulo da atividade associada.

Este relatório irá descrever detalhadamente as etapas seguidas no processamento e análise destes dados, desde a preparação inicial até à fase de aprendizagem computacional, com o intuito de construir um modelo capaz de reconhecer e classificar atividades humanas com base nos sinais captados pelos sensores.

2 Análise Exploratória e Identificação de Outliers (3)

Neste capítulo, procede-se à análise exploratório dos dados transformados, com especial foco nos módulos dos vetores de aceleração, giroscópio e magnetómetro. O objetivo principal é compreender o comportamento das variáveis obtidas a partir dos sensores e identificar possíveis outliers que possam influenciar a qualidade da análise e o desempenho dos modelos de aprendizagem computacional.

Inicialmente, serão apresentados boxplots correspondentes a cada atividade registada no data set, permitindo observar a distribuição e a variabilidade dos módulos dos vetores em função das diferentes atividades. Em seguida, é realizada uma análise da densidade de outliers presentes nos dados transformados, considerando apenas os sensores do pulso direito.

Posteriormente, será implementada uma rotina baseada no teste Z-Score, permitindo identificar e assinalar outliers de forma parametrizável, ajustando o limiar de deteção (k) para diferentes valores. Através desta abordagem, os pontos classificados como outliers serão visualizados graficamente a vermelho, enquanto os restantes serão apresentados a azul, de modo a facilitar a interpretação visual dos resultados.

Na fase seguinte, será implementado o algoritmo k-means, utilizado para segmentar os dados em n-grupos (clusters) e detetar possíveis outliers com base na distância de cada ponto ao centroíde do seu cluster. Serão testados diferentes números de grupos e os resultados serão comparados com os obtidos através do métodos do Z-Score.

Cada uma das secções seguintes apresenta a implementação do código correspondente, os resultados obtidos e uma breve discussão sobre as observações realizadas, incluindo representações gráficas — tanto em 2D como em 3D — que ilustram o comportamento dos dados e a localização dos outliers em cada cenário analisado.

2.1 Análise dos BoxPlots dos Módulos dos Vetores (3.1)

Nas figuras 1, 2 e 3 os boxplots correspondestes aos módulos dos vetores de aceleração, giroscópio e magnetómetro, representados em função das 16 atividades registadas no dataset. Estes gráficos permitem observar a distribuição dos valores medidos, vem como a presença de outliers e a variabilidade associada a cada tipo de sensor.

No gráfico relativo ao acelerómetro, é possível observar uma distribuição heterogénea dos valores entre as diferentes atividades. Algumas categorias,

como as atividades 5,6 e 7, apresentam valores medianos mais elevados e uma maior dispersão dos dados, refletindo uma maior intensidade ou variação do movimento corporal. Além disso, nota-se uma densidade considerável de outliers, o que é expectável em atividades com movimentos bruscos ou irregulares. Por outro lado, atividades como as 1,2 e 10 evidenciam menor variação, sugerindo movimentos mais estáveis ou de baixa intensidade.

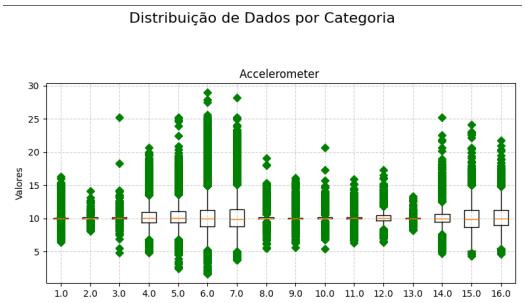


Figura 1: BoxPlot vetor de aceleração

Em relação ao giroscópio, que mede a velocidade angular vemos uma dispersão bastante acentuada me determinadas atividades, nomeadamente nas 5,6 e 7, onde se observam valores máximos muito superiores aos restantes. Isto indica que estas atividades envolvem rotações rápidas ou movimentos angulares intensos. O número de outliers é também expressivo, o que pode estar relacionado com picos momentâneos de rotação. Em contrapartida as atividades 2,8 e 12 mostram distribuições mais compactas e medianas baixas, indicando movimentos menos rotacionais.

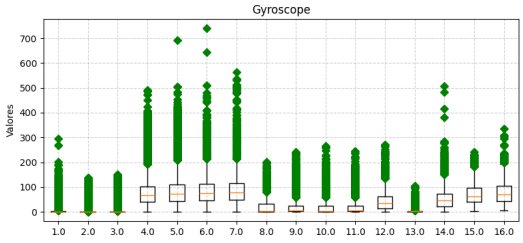


Figura 2: BoxPlot vetor do giroscópio

No gráfico referente ao magnetómetro observa-se uma menor variabilidade global e valores significativamente inferiores aos dos outros sensores. A maioria das atividades apresenta distribuições semelhantes, com poucos outliers e medianas próxmias entre si. Apenas algumas, como a 6 e a 7, mostram ligeira dispersão superior, o que pode estar associado a variações momentâneas no campo magnético devido à orientação corporal.

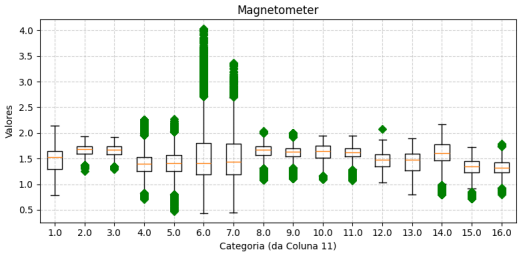


Figura 3: BoxPlot vetor do magnetómetro

De forma geral, conseguimos concluir que os sensores da aceleração e giroscópio captam maior variação e são mais sensíveis a atividades com movimento físico intenso, enquanto o magnetómetro apresenta leituras mais estáveis e com menos dispersão. A presença de outliers sugere que existem picos de movimento ou variações abruptas que deverão ser cuidadosamente tratados nas etapas seguintes de pré-processamento, nomeadamente através de técnicas de normalização ou remoção de outliers.

2.2 Análise da Densidade de Outliers (3.2)

Fazendo uma análise da densidade de outliers reparamos que o acelerómetro apresenta valores moderados, variando entre 0.22% e 19.80%, com destaque para as atividades 8, 9, 10, 11 e 14, que apresentam valores acima de 10%. Estas atividades evidenciam maior irregularidade ou intensidade de movimento, o que se traduz em leituras mais dispersas e na presença de picos significativos nos módulos de aceleração. Por outro lado, atividades como a 2 e 3 apresentam percentagens muito baixas (inferiores a 1%), sugerindo movimentos mais uniformes e estáveis.De forma geral, a dispersão observada no acelerómetro indica que certas atividades geram padrões de movimento mais complexos, o que pode representar comportamentos dinâmicos típicos de ações físicas intensas.

No caso do giroscópio, as densidades variam entre 1.43% e 11.87%, revelando uma distribuição mais equilibrada de outliers entre as atividades. As percentagens mais elevadas observam-se nas atividades 1, 3, 9, 10 e 11, o que sugere maior variação na velocidade angular durante a execução destas tarefas.As atividades com menor densidade (por exemplo, 4, 5, 6, 7 e 14) indicam movimentos rotacionais mais consistentes, com menos variações abruptas. Este comportamento sugere que o giroscópio tende a registar menor sensibilidade a ruído e uma distribuição mais estável do que o acelerómetro, embora continue a refletir a complexidade de certas atividades.

O magnetómetro apresenta, de forma geral, as menores densidades de

outliers, variando entre 0% e 7.35%. A maioria das atividades apresenta valores inferiores a 2%, evidenciando a estabilidade e consistência das medições do campo magnético.Exceções notáveis incluem as atividades 2, 9, 11, 14 e 15, nas quais a densidade ultrapassa os 6%, o que pode estar associado a variações momentâneas na orientação corporal ou interferências externas no campo magnético. Apesar disso, o comportamento global do magnetómetro confirma que este sensor é menos suscetível a picos extremos e apresenta menor variabilidade em comparação com os outros dois sensores.

De forma global, esta análise evidencia que os dados de aceleração e rotação possuem maior dispersão e ruído, enquanto o campo magnético é mais estável. Esta diferença é relevante para as fases seguintes da pipeline, nomeadamente na normalização e seleção de características, uma vez que a presença de outliers pode influenciar negativamente o desempenho de modelos de aprendizagem computacional.

2.3 Comparação entre Z-Score e BoxPlot (3.5)

Para termos um metódo comparativo com o boxplot e vermos se não estamos a excluir dados importantes para a implementação do modelo de classificação, implementamos o método Z-Score com k=3, 3.5 e 4.

No caso do acelerómetro, a aplicação do método Z-Score demonstrou um comportamento dependente do parâmetro k, que defifne o limiar de desvio padrão para identificar outliers. Com k igual a 3.0, o método detetou um número considerável de outliers, concentrando-se principalmente nas categorias intermediárias de 4 a 7. Esse nível de sensibilidade permite identificar tanto valores moderadamente atípicos quanto extremos. Ao aumentar o parâmetro k para 3.5, observa-se um redução significativa no número de outliers, mantendo apenas casos mais expressivos. Qaundo k é 4.0 a deteção torna-se ainda mais conservadora, capturando exclusivamente os valores mais extremos. No entanto na análise pelo BoxPlot apresenta outliers distribuídos em praticamente todas as categorias, com uma maior concentração nas categorias 4 a 7. Com esta análise conseguimos concluir que o Z-Score com k igual a 3 tem um comportamento semelhante ao BoxPlot que nos diz que a escolha do parâmetro k é critica.

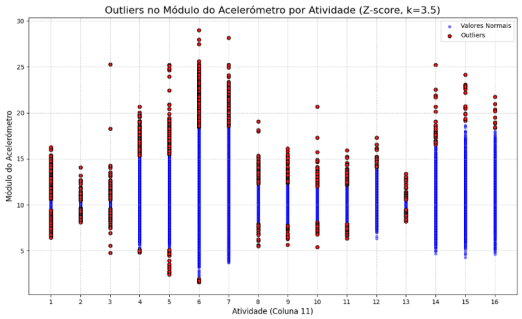


Figura 4: Z-Score Acelerómetro (k=3.5)

No girsocópio temos um padrão semelhante ao do acelerómetro. O Z-Score concentra os outliers nas categorias intermediárias, e a sensibilidade diminui à medida que o parâmetro k aumenta. Já o BoxPlot apresenta uma deteção mais agressiva, especialmente para valores extremamente altos, que chegam a superar 700 unidades. Isso evidencia que o BoxPlot é mais eficiente na captura de outliers extremos que o Z-Score em limiares elevados, tornando-se especialmente útil para identificar anomalias significativas nesse tipo de sensor.

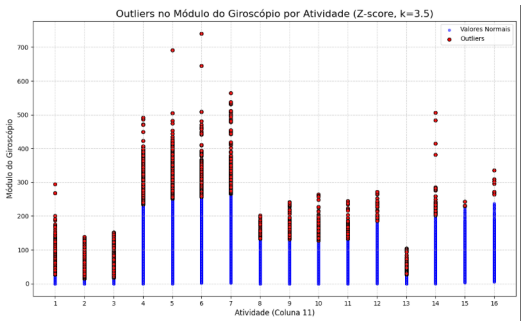


Figura 5: Z-Score Giroscópio (k=3.5)

O comportamento do magnetômetro, por sua vez, mostrou a mais discrepância entre os dois métodos. A aplicação do Z-Score resultou em uma deteção bastante conservadora, mesmo com k igual a 3 enquanto valores mais elevados de k praticamente não identificaram nenhum outlier. O BoxPlot, contrariamente, detetou outliers distribuídos em várias categorias, principalmente nas faixas 5 a 7, embora os valores extremos fossem menos expressivos do que nos outros sensores. Essa diferença ressalta a limitação do Z-Score em contextos nos quais os dados apresentam distribuições não-normais ou menos variáveis, evidenciando a robustez do BoxPlot.

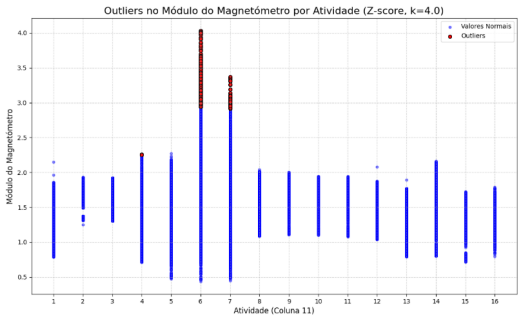


Figura 6: Z-Score Magnetômetro(k=4.0)

Concluido esta comparação entre os dois métodos para a análise de outliers nesta situação, a utilização combinada de ambos os métodos peode ser uma abordagem estratégica, permitindo que se beneficie da robustrez do BoxPlot na deteção de anomalias, ao mesmo tempo em qu se utiliza o Z-Score para ajustes paramétricos finos, garantindo uma análise completa e confiável dos dados de sensores.

2.4 Comparação do K-Mean com Z-Score (3.7)

O K-Means, sendo um método de clustering espacial, agrupa os dados em k clusters com base na distância euclidiana, atribuindo cada ponto ao centróide mais próximo. Os pontos que se encontram distantes de todos os centróides tendem a ser classificados como outliers. Na imagem analisada, é possível observar que o K-Means, com n=3 e n=5, formou um grupo anômalo de pontos vermelhos, espacialmente separado do aglomerado principal de pontos azuis. Esse comportamento indica que o método conseguiu identificar uma região do espaço tridimensional, cujo padrão de movimento é significativamente distinto do comportamento médio do dispositivo.Importante também dizer que, apesar do diferente número de centros utilizados os pontos não havia grande diferença na identificação dos outliers.

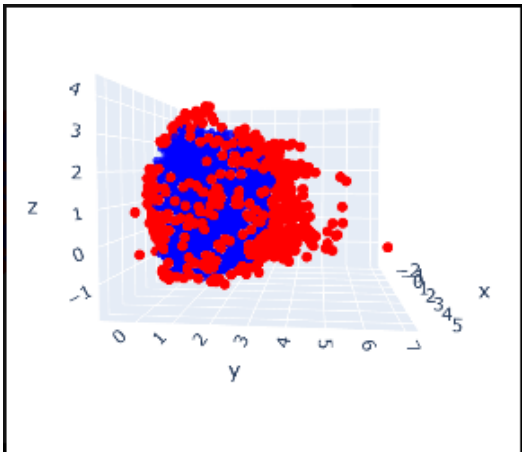


Figura 7: K-Means (k=3.0)

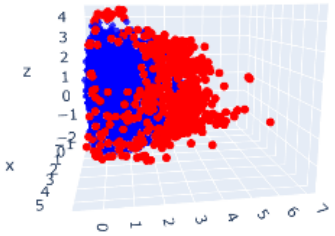


Figura 8: K-Means(k= 5.0)

Ao comparar os resultados observados na imagem, percebe.se que o cluster vermelho identificado pelo K-Means representa um grupo coeso de pontos que não necessariamente apresentam valores extremos em nenhum dos eixos individualmente, mas que, em conjunto, formam um padrão espacial atípico. Trata-se portanto, de um tipo de anomalia que o Z-Score univariado dificilmente detetaria, que este se baseia em desvios independentes em cada dimensão. Nesse caso, o K-Means mostra-se claramente superior, por considerar as relações espaciais entre os eixos e detetar comportamentos coletivos anómalo no espaço tridimensional.

Concluindo, para os dados representados, o K-Means mostrou-se mais eficiente na deteção de comportamentos anómalo espacias, enquanto o Z-Score complementa essa análise ao identificar valores extremos pontuais. Ao analisar a imagem, vemos claramente que o K-means foi capaz de identificar um grupo espacialmente distinto de pontos, algo que o Z-Score univariado

provavelmente não capturaria com a mesma precisão. Assim a recomendação geral é o uso combinado dos dois métodos.

3 Extração de Informação (4)

Este capítulo tem como objetivo reduzir o espaço de representação dos dados, extraindo as características mais relevantes e discriminantes para a classificação das atividades humanas. Numa primeira fase, é analisada a significância estatística dos valores médios das variáveis derivadas dos módulos dos vetores de aceleração, giroscópio e magnetómetro entre as diferentes atividades, recorrendo a testes de normalidade, como o Kolmogorov–Smirnov. Esta etapa permite compreender a variabilidade dos dados e identificar variáveis potencialmente úteis para distinguir padrões de movimento.

De seguida, são aplicadas técnicas de redução e seleção de características, nomeadamente a Análise de Componentes Principais (PCA), o Fisher Feature Score e o ReliefF. O PCA é utilizado para determinar o número mínimo de dimensões necessário para explicar 75% da variabilidade dos dados, enquanto os métodos de Fisher e ReliefF permitem identificar as características mais relevantes para o problema de classificação.

3.1 Análise e Interpretação dos Resultados (4.1)

Os resultados obtidos mostram que, para os módulos do acelerómetro, giroscópio e magnetómetro, nenhuma das 16 atividades analisadas apresentam distribuições totalmente normais segundo o teste de Kolmogorov–Smirnov. Dada a ausência de normalidade foi aplicado o teste não paramétrico Kruskal–Wallis, que resultou em valores-p praticamente nulos, para todos os sensores.

Estes resultados indicam que existem diferenças estatisticamente significativas entre as atividades, o que sugere que os módulos dos três sensores possuem poder discriminante relevante e poderão ser utilizados de forma eficaz em processos de classificação.

A rejeição generalizada da hipótese de normalidade pelo teste Kolmogorov–Smirnov deve ser interpretada com prudência. Em amostras de grande dimensão, este teste torna-se extremamente sensível, assumindo desvios mínimos em relação à normalidade, como estatisticamente significativos. Assim o facto de todos os grupos rejeitarem a normalidade não implica necessariamente que os dados sejam fortemente não normais, mas sim que a dimensão da amostra potencia a sensibilidade do teste.

3.2 Extração de Features(4.2)

Nesta parte do projeto foi-nos pedido que extraissemos as features referidas no artigo "BodyNets '11: Proceedings of the 6th International Conference

on Body Area Networks", neste foi feita referência a features temporais espectrais, físicas e de correlações axiais. Seguindo os procedimentos do artigo, usando os 3 eixos de cada sensor, e todas as features referidas, acabariamos com um uma matriz de vetores com cerca de 104 features. No artigo apenas são usados os sensores acelarometro e giroscopio, no nosso trabalho usamos apenas esses dois sensores.

Para o nosso projeto no entanto, decidimos que iríamos considerar cada device como tendo as suas features individualmente, uma abordagem mais natural seria extrair as features de cada dispositivo em cada utilizador, sincronizando os 5 devices de cada utilizador e extraindo as features de cada dispositivo em cada sliding window válida. O nosso vetor será 5 vezes maior, o que torna o problema muito mais complexo. Para resolver esse problema de complexidade decidimos trabalhar com os módulos dos sensores também, dessa forma conseguimos reduzir a dimensionalidade dos dados. Usando então todas as features referidas no artigo, identificamos quais necessitavam dos eixos dos sensores e quais poderiam usar apenas os módulos. Desta forma reduzimos a dimensionalidade da matriz de features para quase metade. Cada vetor terá então 445 features, 89 por device:

- 66 features estatísticas: 11 features $\times$ 6 eixos (ax, ay, az, gx, gy, gz)
- 6 features espectrais: 3 features $\times$ 2 módulos (a,g)
- 11 features físicas: calculadas a partir de todos os eixos
- 6 features de correlação: entre pares de eixos

Para a extração de features implementamos uma sliding window que percorre os dados temporais de forma sequencial, dividindo-os em segmentos de tamanho fixo com sobreposição controlada. Especificamente, utilizamos janelas de 5 segundos (250 amostras a 50 Hz) que se deslocam com um passo de 2,5 segundos (125 amostras), correspondendo a uma sobreposição de 50%.Este método permite capturar padrões temporais locais das atividades, criando múltiplas instâncias de treino a partir de uma sequência contínua de dados. Por exemplo, numa gravação de 10 segundos, obtemos 3 janelas válidas que se sobrepõem parcialmente, aumentando significativamente o volume de dados disponíveis para treino e teste do modelo.Durante o processo, cada janela deve conter dados de uma única atividade (janelas com transições entre atividades são descartadas) e os cinco dispositivos devem estar sincronizados temporalmente, garantindo que todos analisam o mesmo instante temporal. Apenas após estas verificações é que extraímos as 89 features de cada dispositivo, resultando num vetor final de 445 características para cada janela válida.

3.3 Análise do PCA (4.4)

Após a aplicação do PCA ao conjunto de dados normalizado, verificou-se que seriam necessárias 33 componentes principais para explicar aproximadamente 75% da variabilidade total do espaço de features. Assim, os dados originais foram projetados neste novo espaço de dimensão reduzida, resultando num conjunto comprimido de 33 features derivadas.

Cada nova feature corresponde a uma combinação linear das variáveis originais, ponderadas pelos coeficientes associados a cada componente principal. Desta forma, os dados passam a estar representados em termos das direções que melhor captam a variância global do sistema, preservando a informação mais relevante para a tarefa de classificação.

Depois de aplicar o PCA as features comprimidas obtêm-se multiplicando os dados normalizados pela matriz dos componentes principais. Ou seja se pegarmos num exemplo da matriz de feautures normalizada x[i,:] e multiplicarmos pelas componentes principais extraídas através do pca o resultado são as features comprimidas desse instante ou seja a representação reduzida do novo espaço pca.

Este processo permite uma representação mais compacta e informativa dos dados, reduzindo a redundância entre variáveis e mantendo a maior parte da variabilidade estatisticamente relevante.

A aplicação da análise PCA apresenta várias vantagens e algumas limitações que importa destacar. Entre as vantagens está a capacidade de reduzir a dimensionalidade do conjunto de dados, eliminando redundâncias e mantendo maior parte da variabilidade explicada. Isto permite simplificar o modelo, reduzir o ruído e melhorar a eficiência computacional sem perda significativa de informação relevante. Além disso, o PCA facilita a visualização de dados complexos, tornando mais clara a relação entre variáveis e atividades. No entanto a transformação das variáveis originais em componenetes principais faz com que estas percas interpretabilidade direta, dificultando a análise física ou semântica dos resultados. Adicionalmente, o PCA assume relações lineares entre as variáveis fazendo este método sensível à escala dos dados e presença de outliers, podendo distorcer a variância explicada caso estas condições não forem devidamente controladas.

3.4 Análise do Fisher e ReliefF (4.6)

Análise das features mais relevantes através dos métodos Fisher Score e ReliefF permitiu identificar diferenças na forma como cata técnica avalia a importância das variáveis. O Fisher destacou features associadas ao sensor dev4 o que sugere que estas dimensões contêm informação para distinguir en-

tre diferentes atividades físicas. Estas features estão fortemente relacionadas com a intensidade e a varaição do movimento, o que é coerente com o tipo de dados esperados neste contexto.

No entanto o método ReliefF atribuiu maior relevância a features relacionadas com a variabilidade e a frequência dos sinais, distribuídas por diferentes sensores. Este método tende a capturar relações locais entre amostras próximas, valorizando features que discriminam bem entre as atividades. Importante denotar que neste método, de inicio, foi testados valores de 5 e 10 neighboors para o calculo da importância das variáveis, o que apresentava bastantes features com valores negativos, que significa o feature set tinha bastante ruído. Para solucionar este problema aumentamos o número de neighboors para 100.

Apesar das diferenças, ambos os métodos identificam as features dev4_ay_mean e dev4_ay_median como relevantes, o que reforça a sua importância no reconhecimento das atividades. Assim, pode concluir-se que o Fisher Score fornece uma visão global da discriminação entre classes, enquanto o ReliefF complementa essa análise ao identificar features relevantes em contextos locais, sendo ambos métodos complementares na seleção de variáveis discriminantes.

Depois de identificar as features mais relevantes com base nos métodos Fisher Score e ReliefF, é possível construir um novo feature set composto apenas por estas variáveis. Este processo consiste em selecionar as colunas correspondentes às features com maior pontuação em cada método, assim mantendo apenas a informação mais importante para o problema de classificação.

Por exemplo, se selecionarmos as 10 melhores features de acordo com o Fisher Score, o vetor de características de um instante específico poderá ser representado como:

$$X_{\text{Fisher}} = [\, dev4_ay_rms,\ dev4_ay_median,\ dev4_ay_mean,\ \ldots,\ dev5_gy_rms \,]$$

Esta abordagem de seleção de features apresenta diversas vantagens. Em primeiro lugar, permite reduzir significativamente a dimensionalidade do problema, eliminando variáveis redundantes ou pouco relevantes, o que melhora a eficiência computacional e pode aumenta a precisão dos modelos de aprendizagem

Contudo, esta abordagem também tem limitações. A seleção é dependente dos dados e pode não generalizar bem a outros conjuntos ou contextos de recolha. No caso Fisher Score, assume-se independência entre features, o que pode ser uma simplicação excessiva. Já o ReliefF é sensível ao ruído e ao número de vizinhos escolhidos. Assim, a escolha adequada do método e

a validação dos resultados são etapas essenciais para garantir a redução de features mantém a representatividade e a robustez do modelo e classificação

4 Data Augmentation (1.B)

Nesta secção é nos pedido para analisar a diferença de quantidade de dados entre atividades para verificar se os dados estão balanceados, ou seja, têm todas um numero semelhante de amostras. Fazendo um gráfico para analisar o numero de dados das primeiras 7 atividades concluímos que temos um dataset desbalanceado, em que apesar das atividades 1,2,4 e 5 terem um numero semelhante de dados as atividades 3,6 e principalmente a 7, tem um numero menor de dados. Para resolver este problema é nos pedido para aplicar o método SMOTE que consiste em gerar amostrar sintéticas através de interpolação entre exemplos reais das classes com menos dados. A utilização deste metodo permite equilibrar o dataset para melhorar o desempenho dos modelos de classificação.

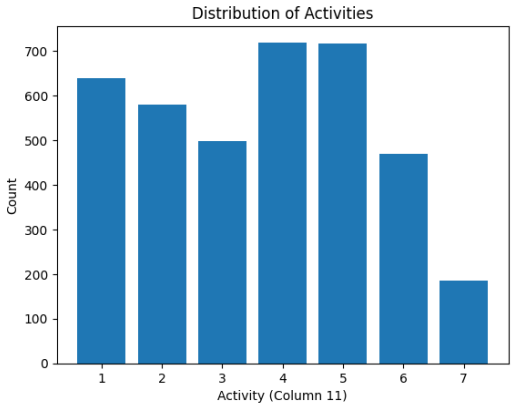


Figura 9: Distribuição de dados por atividade

Ao aplicar o método ao dataset, vemos que para a feature 1 e feature 2, como são features com alta correlação entre si os dados gerados acabam por ficar dentro da linha onde todos os dados ficam. No entanto se avaliarmos features com pouca correlação entre si, como a feature 1 e a feature 44, conseguimos ver a diferença que os dados gerados acabam por ter entre si como demonstrado na figura 10.

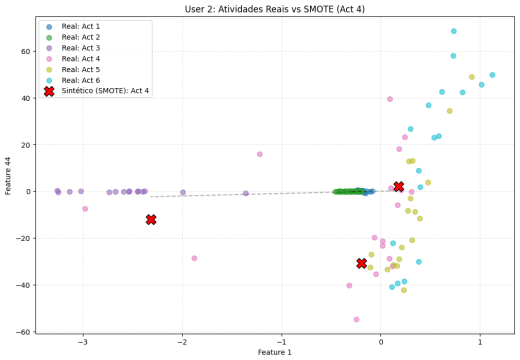


Figura 10: Atividades Reais vs SMOTE

5 Data Splitting Strategy (3.3.B)

Na divisão dos dados para treino, teste e validação são propostas duas estratégias distintas de dividir o dataset. A primeira consiste numa divisão intra-subject, onde cada pessoa está presente de forma equilibrada em todas as partições. Neste caso, os dados de cada sujeito são segmentados e distribuídos de modo proporcional pelos conjuntos de treino, validação e teste. A segunda estratégia corresponde a uma divisão inter-subject, em que um conjunto de pessoas é exclusivamente para treino, enquanto os restantes sujeitos são reservados para validação e teste.

Ambas as abordagens são validas, mas servem propósitos diferentes a apresentam desafios distintos para os modelos. A divisão intra-subject tende, em teoria, a produzir melhores métricas de avaliação.Isto acontece porque o modelo tem acesso, durante o treino, a padrões específicos de cada pessoa que também estarão presentes na validação e no teste fazendo a distribuição entre as partições mais homogénea. Esta abordagem é útil em contextos académicos, onde o foco está na otimização do desempenho do modelo com base nos dados disponíveis.

No entanto, a divisão intra-subject tem limitações práticas quando se pretende prever movimentos na vida real. Em ambientes reais, o sistema deve ser capaz de generealizar para indíviduos que nunjca foram observados anterriormente. Nestas situações, a divisão inter-subject é mais realista, pois obriga o modelo a aprender padrões gerais do movimento humano, em vez de padrões particulares de cada pessoa. Esta divisão é mais desafiante e resulta em métricas mais baixas mas fornece uma avaliação mais fiel da capacidade de generalização do modelo.

6 Model Learning (4.B)

Para a avaliação dos modelos, considerámos três variantes do dataset de features e três variantes do dataset de embeddings, aplicadas em ambas as estratégias de divisão dos dados (intra-subject e inter-subject). No total, foram assim avaliadas doze configurações experimentais (3 variantes de features + 3 variantes de embeddings $\times$ 2 estratégias de divisão). Todas as variantes seguiram o mesmo protocolo de pré-processamento e avaliação, garantindo comparações justas entre métodos. As variantes exploradas foram:

- Todas as features / todos os embeddings (sem redução);
- Features reduzidas por PCA / embeddings reduzidos por PCA (com componentes suficientes para explicar 90
- Features selecionadas / embeddings selecionados (com as 15 melhores features escolhidas pelo algoritmo ReliefF).

É importante notar que tanto o PCA como o ReliefF foram aplicados exclusivamente ao conjunto de treino. Isto evita a fuga de informação para os conjunto de validação e teste, que poderia comprometer a imparcialidade da avaliação do modelo. Na pratica, o PCA foi ajustado apenas sobre os dados de treino e posteriormente aplicado aos dados de validação e teste usando os mesmo componentes calculados no treino. Da mesma forma, a seleção de features pelo ReliefF utilizou unicamente o conjunto de treino para determinar as features mais relevantes, aplicando essa mesma seleção aos restantes conjuntos sem recalcular qualquer métrica. Esta separação garante que tanto a redução de dimensionalidade como a seleção de feature não influenciam indevidamente os resultados.

O modelo utilizado para a classificação das atividades foi o k-Nearest Neighbors (KNN). Este algoritmo baseia-se no princípio de que dados semelhantes tendem a estar próximos no espaço das features. Desta forma, o KNN classifica uma observação desconhecida analisando os k pontos mais próximos no conjunto de treino, medindo tipicamente a distância Euclidiana, e atribuindo a classe mais frequente entre esses vizinhos

Para otimizar o desempenho dos modelos, realizámos hyperparameter tuning, testando diferentes valores de k exclusivamente sobre os dados de treino. O objetivo foi identificar o valor que maximizava as métricas de avaliação, aplicando posteriormente esse k ótimo aos dados de validação e, finalmente, ao conjunto de teste.

7 Avaliação (5.B)

A análise dos resultados obtidos para as diferentes variantes do dataset e para as duas estratégias de divisão dos dados permitiu identificar que o melhor desempenho foi alcançado pelo modelo treinado com a divisao intra-subject, utilizando todas as features e com um valor de K= 1 no classificador KNN. Este desempenho superior pode ser explicado pelo facto de, na abordagem intra-subject, os dados de cada pessoa estarem distrbuidos pelos conjuntos de treino, validacao e teste, o que reduz a variabilidade entre conjuntos e facilita a generalização do modelo. Além disso, a utilizacao de todas as features mantém a informaçao original completa, incluindo detalhes especificos dos movimentos que sao relevantes para distinguir diferentes atividades. O valor reduzido de k, neste caso K= 1, favorece igualmente esta abordagem, uma vez que permite ao modelo capturar variações individuiais com maior precisão, algo que funciona particularmente bem quando as amostras de teste são semelhantes às do treino. A observação dos resultados mostra ainda que os erros começam a surgir sobretudo a partir da atividade 4, o que se explica pela maior semelhança entre os movimentos envolvidos nessas atividades.

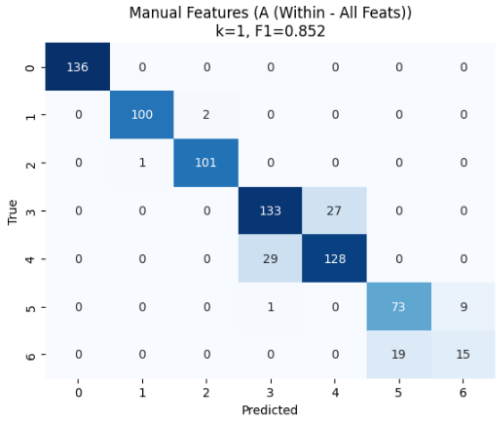


Figura 11: Matriz de Previsão

Em contraste, o pior desempenho foi verificado na configuração baseada em embeddings com seleção de 15 features através do algoritmo ReliefF, utilizando a divisão inter-subject e com k = 7. Este resultado mais fraco deve-se a vários fatores combinados. Em primeiro lugar, a divisão inter-subject implica que o modelo é avaliado com dados de indivíduos que não foram incluídos no treino, aumentando significativamente a variabilidade dos padrões de movimento e dificultando a capacidade de generalização. Além disso, os embeddings e a seleção de apenas 15 features reduzem bastante

a quantidade de informação disponível, o que, embora possa ser útil em cenários intra-subject, tende a eliminar características importantes para lidar com diferenças entre pessoas. Por fim, utilizar k = 7 torna o modelo mais "suave" na tomada de decisão, o que reduz a sua sensibilidade a detalhes específicos de cada atividade. Em contextos com elevada variabilidade entre sujeitos, esta suavização leva a uma maior taxa de erros, dado que o modelo passa a privilegiar padrões médios que nem sempre são representativos dos movimentos reais de cada indivíduo.

Comparando o desempenho entre o feature set e o embedding set nas diferentes transformações aplicadas, verifica-se que o feature set apresenta consistentemente melhores resultados de precisão, independentemente da estratégia de divisão dos dados utilizada para treino, validação e teste. Da mesma forma, observa-se que a divisão intra-subject supera sistematicamente a divisão inter-subject, evidenciando que a presença de dados de cada indivíduo nos três conjuntos reduz a variabilidade entre sujeitos e facilita a generalização do modelo.

Para determinar se o melhor modelo obtido é estatisticamente superior aos restantes modelos, foi realizado um teste estatístico de comparação pareada entre modelos. O teste estatísco utilizado foi o teste de Wilcoxon Signed-Rank uma vez que este teste não assume normalidade, uma vez que a distribuição dos F1-scores não pode ser assumida como normal, é apropriado para comparar métricas de desempenho e dá para fazer os teste com uma comparação pareada, o que seria um dos maiores motivos da escolha deste teste, tendo em conta que cada modelo possui vários valores de F1-score correspondentes às mesmas execuções.

Comparando o melhor modelo com os restantes pelo teste estatistico vemos que os p-values dos diferentes teste ficaram entre 0.00195 e 0.00391, ou seja os p-values foram todos inferiores a 0.05, ou seja, a diferença é estatisticamente significativa e rejeitamos a hipótese nula de que os modelos têm desempenhos equivalentes, fazendo nos concluir que o modelo intra-subject com todas as features é estatisticamente superior a todos os outros modelos considerados, com um nível de significância de 5%.

8 Potenciais Melhorias

Apesar de o modelo apresentar uma precisão bastante satisfatória, existe sempre espaço para melhorias que podem contribuir para um sistema de classificação mais robusto e generalizável. Uma das primeiras possibilidades de melhoria consiste no tratamento adequado de outliers presentes no dataset. Embora tenha sido aplicada uma normalização via z-score, esta técnica é

sensível a valores extremos, já que os outliers influenciam significativamente a média e o desvio-padrão utilizados no cálculo. Como consequência, alguns dados podem permanecer mal normalizados, prejudicando a distribuição das features e, potencialmente, o desempenho do modelo. Métodos alternativos, como normalização robusta, winsorization, ou a deteção e remoção direta de outliers através de técnicas como IQR ou Isolation Forest, poderiam ser explorados para mitigar este efeito.

Outra possível melhoria passa por lidar com o desbalanceamento entre o número de amostras das diferentes atividades. Esta discrepância pode fazer com que o modelo apresente ótimos resultados nas atividades mais representadas e desempenhos claramente inferiores nas atividades com menos dados um fenómeno observado no presente trabalho. Uma estratégia seria aplicar downsampling às classes maioritárias para equilibrar o dataset. Contudo, esta abordagem implica perda de informação, podendo levar a fenómenos de underfitting. Em alternativa, é possível aplicar técnicas de upsampling, como o método SMOTE utilizado neste projeto, que gera amostras sintéticas para as classes minoritárias. Apesar das suas vantagens, o SMOTE também apresenta riscos: se as amostras geradas forem demasiado próximas entre si ou pouco representativas da variabilidade real, o modelo pode ficar excessivamente ajustado, resultando em overfitting.

Outra melhoria seria no intra-subject split, fazermos o split tendo em conta o número de amostras por participante. No nosso projeto assumimos que todos os participantes têm o mesmo número de amostras, ou seja, se o número de amostras estiver desbalanceado, podemos acabar com um split desbalanceado, pois pode haver a possibilidade de os utilizadores com mais amostras acabarem no teste ou na validação, deixando menos dados para o treino.